你說：

【我要用 Kaggle Playground S4E5 洪水預測資料集（20 個特徵）做多元線性回歸作業，請說明：

1. 適合的特徵選擇方法有哪些？
2. 信賴區間和預測區間有什麼不同？
3. 線性回歸需要檢查哪些假設？】**說明**

一、作業目標：
本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。\

二、作業內容：
1. 資料來源
至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。
類型不限（可為房價預測、醫療、車輛效能等主題）。
請明確標示資料集來源與連結。
2. 分析任務
使用線性回歸 (Linear Regression) 模型進行預測。
可嘗試單純線性回歸、多元線性回歸或 Auto Regression。
必須執行 **特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)**。
結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3. CRISP-DM 流程說明
Business Understanding
Data Understanding
Data Preparation
Modeling
Evaluation
Deployment

4. AI協助要求
所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須**匯出為 PDF**
請**使用 NotebookLM** 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」
5. 繳交內容
主程式：7114056XXX_hw2.py/.ipynb
報告檔： PDF，需包含以下內容：

按照 CRISP-DM 說明的分析流程
GPT 對話過程（pdfCrowd 匯出）
NotebookLM 研究摘要
網路上主流或更優解法之比較與說明
以上檔案與資料夾**請壓縮為學號命名的一個zip**（例如 7114056XXX_hw2.zip）上傳。

(optional) 若上傳至 GitHub，或是以colab撰寫，需提供連結，並在 README.md 中整理流程與成果。

三、評分標準
文件說明（50%）
CRISP-DM 流程完整且邏輯清楚（25%）
包含 GPT 對話與 NotebookLM 摘要（15%）
有明確說明資料集來源與研究脈絡（10%）
 結果呈現（50%）
模型正確可執行，具特徵選擇與評估（25%）
結果合理、美觀且具有說服力（15%）
呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)（10%）

ChatGPT 說：

這次 HW2 的重點不只是「使用 Python 訓練一個線性回歸模型」，而是要**利用真實資料，完成特徵選擇、模型建立、預測結果評估，並依照 CRISP-DM 流程解釋整個研究過程。**

你選擇的 **Kaggle Playground Series S4E5 洪水預測資料集（Flood Prediction）**，具有 20 個特徵，符合老師要求的 10～20 個特徵，而且預測目標 `FloodProbability` 是連續數值，適合用來練習多元線性回歸。

以下我會先回答你提出的三個問題，再說明如何實際應用在這次作業中。

一、適合的特徵選擇方法有哪些？

1. 什麼是特徵選擇（Feature Selection）？

多元線性回歸的基本公式是：

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

其中：

- $\hat{y}$：預測的洪水發生機率
- $x_1, x_2, \ldots, x_p$：影響洪水的特徵，例如降雨、都市化程度等
- β_0：截距
- $\beta_1, \ldots, \beta_p$：各個特徵對預測結果的影響係數

你的資料集有 20 個特徵，但不代表一定要全部使用。

特徵選擇的目的，就是找出對預測最有幫助的特徵組合，並減少不必要的模型複雜度。

2. 常見的四種特徵選擇方法

方法	核心概念	適合這次作業嗎？
Pearson Correlation（相關係數）	觀察特徵與目標值的線性相關程度	適合，容易解釋
RFE（遞迴特徵消除）	反覆移除模型認為影響較小的特徵	非常適合
SelectKBest（單變量特徵選擇）	根據統計分數挑選前 K 個特徵	非常適合
Lasso（L1 正則化）	透過懲罰機制將部分係數壓縮至 0	適合進階比較

方法 A：Pearson Correlation

相關係數 r 介於 -1 到 1：

- r 越接近 1：正向線性相關越強
- r 越接近 -1：負向線性相關越強
- r 越接近 0：線性相關越弱

例如，假設分析後得到以下結果（純示意，並非資料集實際結果）：

特徵	與 FloodProbability 的相關係數
MonsoonIntensity	0.42
Deforestation	0.35
Urbanization	0.29
ClimateChange	0.26

我們可以依照相關係數的絕對值排序，挑選較重要的特徵。

但要注意，相關係數只衡量單一特徵與目標之間的線性關係，**無法完整反映多個特徵一起使用時的預測價值**。

方法 B：RFE（Recursive Feature Elimination）

RFE 的概念是：

20 個原始特徵

↓

訓練線性回歸模型

↓

移除係數絕對值較小的特徵

↓

重複訓練與篩選

↓

保留指定數量的特徵，例如 10 個

RFE 可以搭配 `sklearn.feature_selection.RFE` 實作。

不過，因為它會依據模型係數大小篩選，所以使用前最好先將特徵標準化，避免不同量尺影響比較。

方法 C：SelectKBest

SelectKBest 會為每個特徵計算統計分數，再挑選排名前 K 名的特徵。

例如：

```
from sklearn.feature_selection import SelectKBest, f_regression

selector = SelectKBest(score_func=f_regression, k=10)
```

這代表從 20 個特徵中，根據各特徵與目標的單變量線性關係，選出分數最高的 10 個。

它的優點是速度快、實作簡單；缺點是沒有充分考慮特徵之間的交互作用。

3. 我建議這次作業怎麼做？

不需要四種方法全部實作。

我比較建議採用以下三組模型進行比較：

模型	使用特徵	用途
Model A	全部 20 個特徵	建立基準模型
Model B	SelectKBest 選出的特徵	比較單變量篩選效果
Model C	RFE 選出的特徵	比較模型導向篩選效果

可以先嘗試 5、10、15、20 個特徵，利用交叉驗證比較結果，再選出合適的數量。

這樣不只滿足老師的 Feature Selection 要求，也能在 Evaluation 部分呈現有意義的模型比較。

特別注意： 必須先切分訓練集與測試集，再於訓練資料內進行特徵選擇與交叉驗證，避免資料洩漏（Data Leakage）。

二、信賴區間與預測區間有什麼不同？

這是這次作業非常重要的部分，因為老師明確要求：

> 結果部分需包含預測圖（加上信賴區間或預測區間）。

1. 信賴區間（Confidence Interval, CI）

信賴區間主要用來描述：**在給定特徵條件下，模型所估計的平均反應值有多少不確定性。**

例如：

假設某種洪水環境條件下，模型預測的平均洪水機率為 0.55。

其 95% 信賴區間可能為：

$$CI = [0.53, 0.57]$$

這表示我們估計該條件下的平均洪水機率約為 0.55，並以區間表達估計的不確定性。

嚴格來說，95% 信賴水準是指重複抽樣所建立的區間，長期而言約有 95% 能涵蓋真正的平均值，而不是指這次算出的區間有 95% 機率包含固定的真值。

2. 預測區間（Prediction Interval, PI）

預測區間則是用來描述：**在給定特徵條件下，一筆新的實際觀測值可能落在哪個範圍。**

例如：

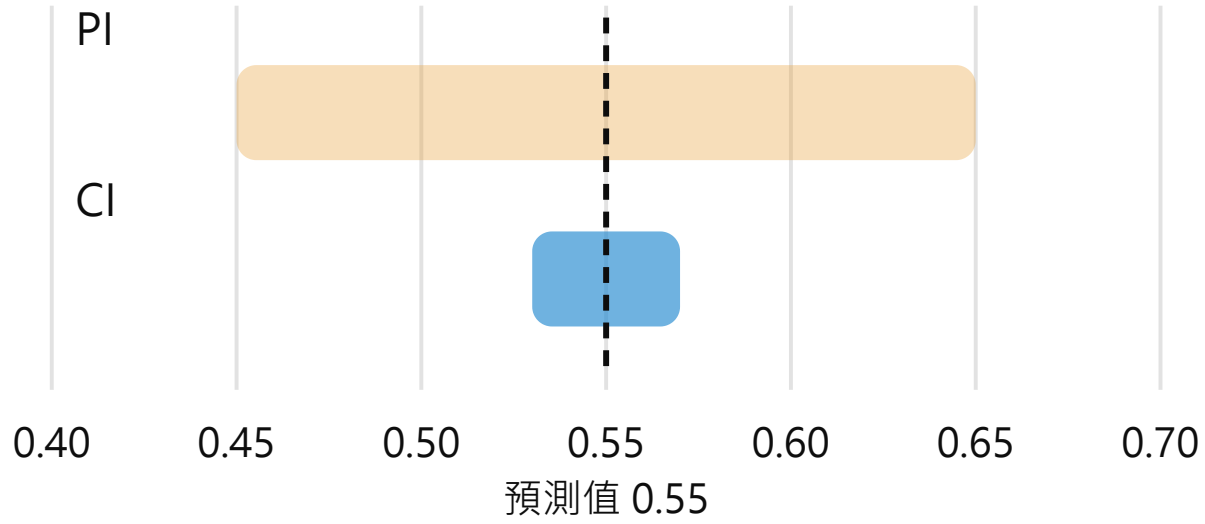
同樣預測洪水機率為 0.55，但 95% 預測區間可能是：

$$PI = [0.45, 0.65]$$

因為新觀測值除了受到模型估計誤差影響，還包含個別樣本本身的隨機變動，所以預測區間通常比信賴區間寬。

3. 兩種區間的比較

示意：同一預測值 0.55 的兩種區間



以上數值僅為教學示例，不代表 Kaggle 資料集的實際結果。

比較項目	信賴區間 CI	預測區間 PI
估計對象	條件平均值	新的一筆觀測值
區間寬度	通常較窄	通常較寬
是否包含個別觀測誤差	否	是
適合這次作業	可以	更推薦

4. 這次作業應該選哪一種？

我建議優先使用 **95% Prediction Interval（預測區間）**。

原因是這次作業的目的為預測洪水機率，而不是單純估計某種環境條件下的平均值。

在 Python 中可以使用 `statsmodels` 建立傳統 OLS 線性回歸模型，再透過 `get_prediction()` 取得信賴區間與預測區間。

但要留意兩件事：

- 傳統 OLS 預測區間需要相關統計假設成立，才能合理解讀其涵蓋率。
- `FloodProbability` 的目標值有 0～1 的範圍限制，而一般線性回歸的預測值及區間不一定落在 0～1 之間，因此報告中應說明這個限制。

三、線性回歸需要檢查哪些假設？

多元線性回歸不只是讓模型產生預測值，也需要檢查模型的統計假設是否合理。

以下是這次作業建議檢查的五個重點。

假設	代表意義	檢查方法
線性關係 Linearity	目標的條件平均值能由特徵線性組合描述	殘差與預測值散佈圖
誤差獨立性 Independence	不同觀測值的誤差不應存在不當依賴	Durbin–Watson、資料來源分析
等變異性 Homoscedasticity	誤差變異數在不同預測水準下大致相同	殘差散佈圖、Breusch–Pagan Test
殘差常態性 Normality	誤差分布近似常態	Q-Q Plot、常態性檢定
無完全多重共線性	特徵之間不存在完全線性依賴	VIF、相關係數矩陣

1. 線性關係

線性回歸假設目標變數的條件平均值，可以用特徵的線性組合表示。

我們可以繪製：

- X 軸：模型預測值
- Y 軸：殘差（實際值減預測值）

如果殘差大致隨機分布於 0 上下，表示線性模型可能是合理的。

如果出現明顯的 U 型、曲線或其他規律，可能代表線性模型沒有捕捉到資料中的某些關係。

2. 誤差獨立性

理想情況下，不同觀測值的誤差不應具有未處理的相關性。

例如，同一地區連續幾天的洪水資料，可能存在時間相關性。

不過，S4E5 是表格型預測資料，是否存在時間或群組依賴，仍需要依據資料產生方式判斷，不能單靠 Durbin–Watson 檢定就認定所有誤差獨立。

3. 等變異性

等變異性指：

$$\mathrm{Var}(\varepsilon_i \mid X) = \sigma^2$$

意思是不同特徵條件下，誤差的變異數相同。

如果殘差圖呈現漏斗形，可能表示存在異質變異（Heteroscedasticity）。

這會影響傳統標準誤、信賴區間及預測區間的可靠性。

4. 殘差常態性

傳統有限樣本 OLS 的 t 檢定、F 檢定與預測區間，通常需要常態誤差假設才能得到精確的分布結果。

常見檢查方式是 Q-Q Plot。

如果資料點大致沿著參考直線分布，代表常態假設可能合理。

但要注意：**線性回歸不要求所有原始特徵都服從常態分布，也不要求殘差必須常態才能計算 OLS 係數。**

5. 多重共線性

如果兩個或多個特徵高度相關，可能使回歸係數不穩定。

例如：

- 降雨強度
- 洪水風險相關氣象指標

兩者可能具有相關性，但是否真的高度相關，仍需以資料分析確認。

可以使用 VIF（Variance Inflation Factor）檢查：

$$VIF_j = \frac{1}{1 - R_j^2}$$

其中 R_j^2 是以其他特徵預測第 j 個特徵所得到的決定係數。

一般而言，VIF 大於 5 或 10 常被當成需要進一步檢查的經驗門檻，但不是絕對標準。

另外，這五項假設中，線性條件平均、誤差的外生性（例如 $E[\varepsilon \mid X] = 0$）、以及沒有完全共線性，對 OLS 係數的解釋尤其重要；常態性與等變異性主要影響傳統統計推論，並非模型能否執行的必要條件。

四、如何把這三個問題整合進 HW2？

根據老師的 CRISP-DM 要求，我建議你的作業採用以下架構。

1. **Business Understanding | 問題定義**

   研究不同環境與人為因素如何影響洪水發生機率，並建立可解釋的預測模型。

2. **Data Understanding | 資料理解**

   讀取 20 個特徵、檢查資料分布、缺失值、異常值與相關係數。

3. **Data Preparation | 資料準備**

   切分訓練集與測試集，進行必要的資料處理，並透過 SelectKBest、RFE 選擇特徵。

4. **Modeling | 模型建立**

   使用 `sklearn.linear_model.LinearRegression` 訓練模型，並比較不同特徵組合。

5. **Evaluation | 模型評估**

   比較 R²、RMSE、MAE，產生預測圖、95% 預測區間，並檢查回歸假設。

6. **Deployment | 模型部署**

   儲存模型，建立可以輸入洪水相關特徵並顯示預測結果的網頁，或提供可重複執行的預測程式。

建議呈現的評估指標

指標	說明	判讀
R²	模型解釋目標變異的程度	越高通常越好

MAE	平均絕對誤差	越低越好
RMSE	均方根誤差	越低越好
PI Coverage	實際觀測值落在預測區間內的比例	與目標涵蓋率比較

其中 **R^2 一定要有**，因為 Kaggle S4E5 官方就是使用 R^2 作為競賽評分指標。 k Kaggle

建議產生的圖表

1. 20 個特徵與目標值的相關係數圖
2. 不同特徵選擇方法的模型表現比較圖
3. Actual vs. Predicted（實際值與預測值散佈圖）
4. 預測結果與 95% Prediction Interval 圖
5. Residual Plot（殘差圖）
6. Q-Q Plot（殘差常態性檢查）

這些圖不需要全部放在主報告正文，但至少應保留特徵選擇結果、預測表現、區間圖與主要診斷圖。

五、NotebookLM 可以研究什麼？

老師要求你使用 NotebookLM 比較網路上的主流或更優解法。

我查到這份資料集的 Kaggle 競賽已於 2024 年結束，官方公開的高分解法中包含 Ridge Regression 與 Ensemble（集成模型）等方法。 k Kaggle +1

你可以把以下資料提供給 NotebookLM：

- Kaggle S4E5 官方競賽資料 ↗
- Kaggle 公開 Notebook 與解法 ↗
- Linear Regression、LightGBM、XGBoost 比較案例 ↗

NotebookLM 的研究重點可以放在：為什麼 Ridge、特徵工程或集成模型可能優於基本線性回歸？它們又犧牲了哪些可解釋性或增加多少複雜度？

另外，這個資料集是**模擬生成的資料**，不是直接蒐集的真實洪水觀測紀錄。因此報告應避免把模型係數直接解釋成真實世界的因果關係。 k Kaggle +1

六、作業繳交前的檢查

HW2 繳交清單 0/10 完成