AIoT HW2 洪水機率預測報告

Oct 15, 2026 · 7115064011 袁靖淇

本報告以多元線性回歸預測洪水機率，驗證集 R^2 為 0.8449，Kaggle Private Score 為 0.84426，並依 CRISP-DM 六階段完成分析與部署。

基本資訊

項目	內容
作業	AIoT HW2：多元線性回歸（Multiple Linear Regression）
學號	7115064011
袁靖淇	袁靖淇
主程式	7115064011_hw2.ipynb
GitHub	AIoT-HW2-regression
資料集	Kaggle Playground Series S4E5 – Regression with a Flood Prediction Dataset
前作 HW1	CWA 台灣天氣預報網站

1. 研究背景與資料來源

本作業延伸自 HW1：HW1 串接中央氣象署 CWA Open Data，建立天氣資料的取得與展示網站；HW2 進一步從資料中建立預測模型，主題同樣與氣象災害相關。

資料集來源：Kaggle Playground Series Season 4 Episode 5（Regression with a Flood Prediction Dataset），競賽期間為 2024 年 5 月 1 日至 6 月 1 日，共 2,788 隊參賽，評分指標為 R^2。

項目	內容
訓練資料	1,117,957 筆
測試資料	745,305 筆
特徵	20 個整數評分特徵（MonsoonIntensity、Deforestation、Urbanization、DrainageSystems 等環境與治理指標）

項目	內容
目標變數	FloodProbability（連續值，0.285 ~ 0.725）

資料性質：本資料為 Kaggle 以原始 Flood Prediction 資料集生成的合成資料，模型僅作方法示範，不代表台灣或任何真實地區的洪水風險。

選擇理由：特徵數為 20 個，符合作業 10–20 個特徵的規定；全為數值特徵、無缺失值，適合專注於線性回歸的建模與評估；且有 Kaggle 排行榜可提交驗證結果。

2. Business Understanding

目標是依 20 項地理、氣象與治理指標預測洪水發生機率，讓防災決策從「災後搶修」轉為「災前預警」。

目標使用者

- 水利與防汛部門：水庫放水、水門與抽水機部署
- 災害應變中心：淒水警報、疏散路線與避難所規劃
- 都市規劃與公共工程部門：排水容量與老舊設施更新評估
- 保險與金融機構：天然災害風險定價

問題定義：監督式回歸問題，輸入為 20 個整數評分，輸出為連續的洪水機率，限定使用線性回歸系列模型。

成功標準

類型	標準	結果
技術	驗證集 $R^2 \geq 0.84$	0.8449，達成
技術	係數可解釋、預測附帶 95% 預測區間	達成
營運	降低高風險區域的預測誤差，提供可靠的防汛決策參考	見第 5 章殘差分析

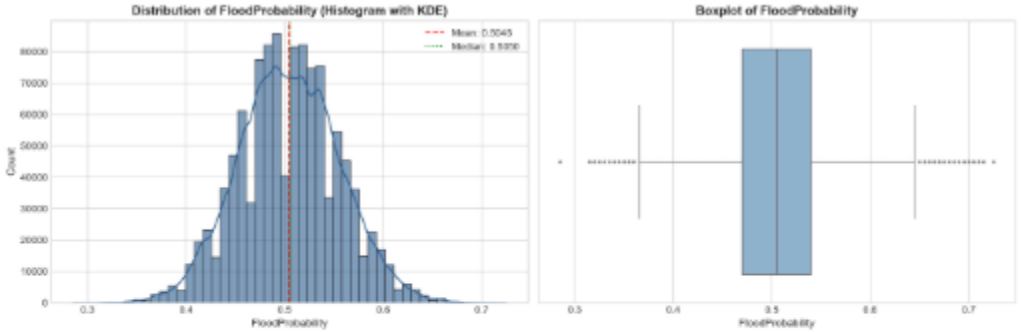
3. Data Understanding

20 個特徵彼此幾乎獨立，與目標的相關係數都只有 0.18 左右；單一特徵解釋力很弱，必須使用多元回歸。

資料品質：共 1,117,957 筆、22 欄（id、20 個特徵、目標），全部欄位無缺失值。

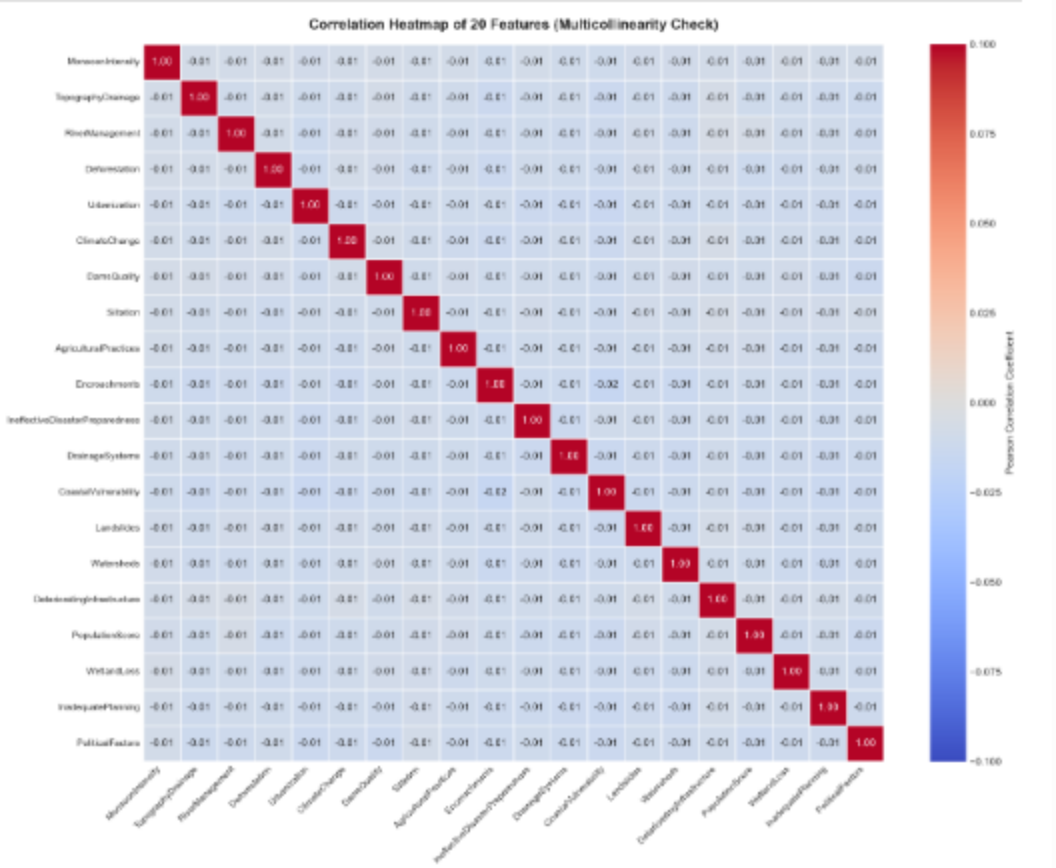
觀察一：特徵為整數評分。各特徵多介於 0–19，平均約 4.9、標準差約 2.06–2.09，分佈稍微右偏（偏態約 0.42–0.46）。

觀察二：目標變數接近常態。FloodProbability 平均 0.5045、標準差 0.0510、偏態 0.047。目標只有 83 種值，以 0.005 為單位，因此直方圖呈梳子狀間隔。



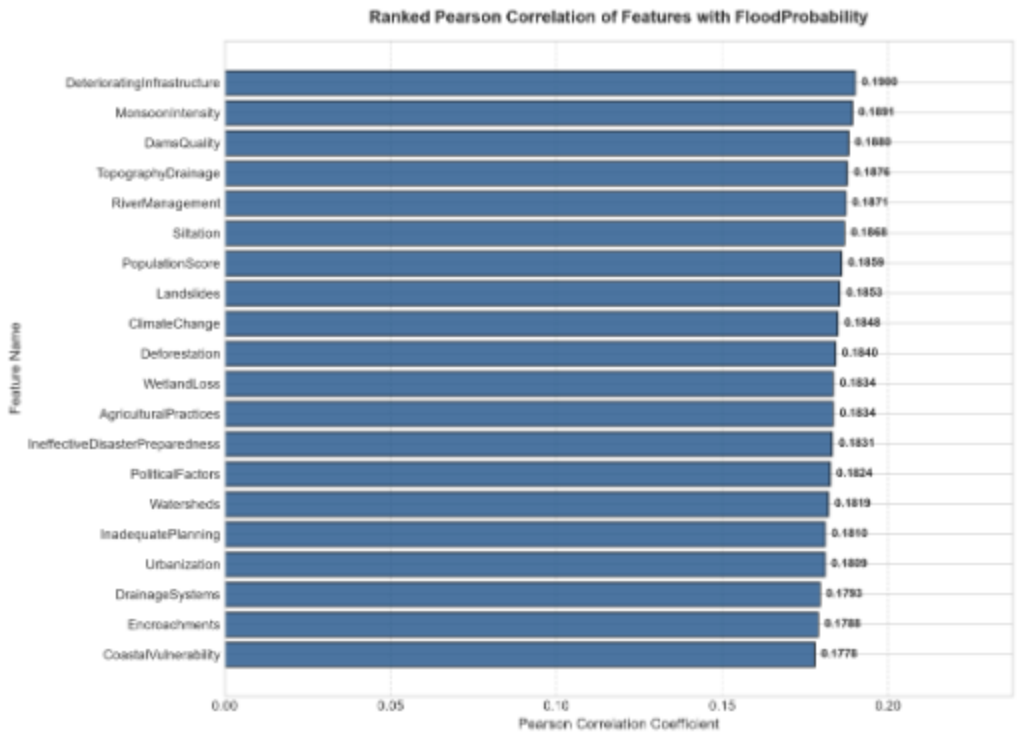

```
Target Summary Statistics:
- Mean: 0.5045
- Std Dev: 0.0510
- Median: 0.5050
- Min: 0.2850, Max: 0.7250
- Skewness: 0.0472 (Near zero: Highly symmetric)
- Kurtosis: -0.0396
```

觀察三：特徵之間幾乎完全不相關。熱圖上所有配對的相關係數約為 -0.01，最高為 CoastalVulnerability 與 Encroachments 的 0.016。真實資料很少如此，是合成資料的特徵，也代表多重共線性風險極低。

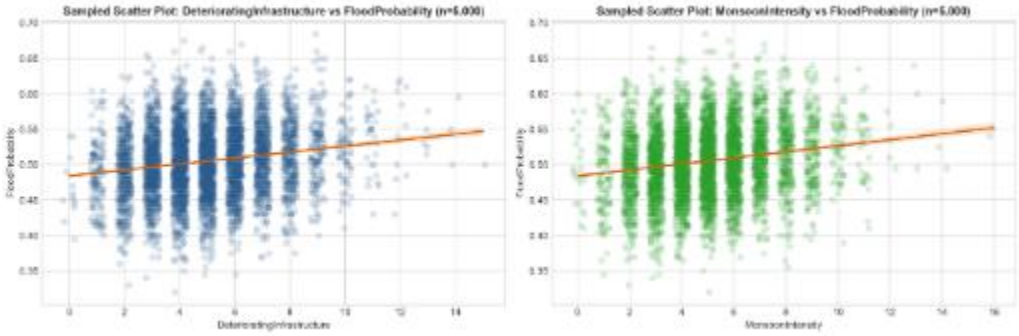



```
Top 5 Feature Pairs with Highest Correlation:
```

觀察四：每個特徵與目標均為弱正相關，強度幾乎一致。相關係數介於 0.178（CoastalVulnerability）至 0.190（DeterioratingInfrastructure）。散佈圖中單一特徵的趨勢線平緩、點很分散。




```
=== Ranked Correlation with Target (Descending) ===
```



觀察五：單獨很弱，合起來很強。單一特徵只能解釋約 3.5% 的變異（$0.19^2 \approx 0.036$）。但 20 個特徵彼此獨立、方向一致，合起來的解釋力遠高於單一特徵，這正是本問題需要多元線性回歸的理由。

4. Data Preparation

三種特徵選擇方法都顯示 R^2 隨特徵數穩定上升、沒有可刪除的冗餘特徵，因此最終保留全部 20 個特徵。

前處理步驟

1. 移除 id，X 為 20 個特徵，y 為 FloodProbability。
2. 切分訓練集與驗證集（80/20，random_state = 42）：訓練集 894,365 筆、驗證集 223,592 筆。

3. StandardScaler 標準化：只用訓練集 fit，再 transform 驗證集。之後所有特徵選擇也只用訓練集，避免資料洩漏。
4. 不建立「特徵總和」等衍生特徵：總和是 20 個特徵的線性組合，加入線性模型會造成完全共線性。

多重共線性檢驗（VIF）：20 個特徵的 VIF 介於 1.0017（MonsoonIntensity）至 1.0037（CoastalVulnerability），遠低於警戒值 5，完全沒有多重共線性。

【插入圖 4-1：VIF 表格】

特徵選擇比較：以 SelectKBest（f_regression）、RFE（LinearRegression，抽樣 10 萬筆）、LassoCV 三種方法排序特徵，取前 k 個訓練 LinearRegression，比較驗證集 R^2。

k（特徵數）	SelectKBest R^2	RFE R^2	LassoCV R^2	占 k = 20 之比例
1	0.0368	0.0368	0.0315	4%
5	0.1833	0.1817	0.1757	22%
10	0.3774	0.3755	0.3748	45%
15	0.5958	0.5968	0.5959	71%
20	0.8449	0.8449	0.8449	100%



結果分析

- 三種方法在同一 k 下的 R^2 差距都小於 0.01，曲線幾乎重疊：特徵與目標的相關強度幾乎相同，排序方式對結果影響不大。
- R^2 沒有出現高原，每拿掉一個特徵都明顯損失準確度；LassoCV 也未將任何係數壓成 0。

- 曲線略向上彎，來自特徵間極微弱的負相關（約 -0.01），使多個特徵合併的解釋力略高於各自相加。
- **結論**：特徵選擇的目的是驗證每個特徵是否值得保留。三種方法一致顯示 20 個特徵都有貢獻，故保留全部 20 個。

5. Modeling

OLS 模型的 R^2 為 0.845，20 個係數幾乎相同，模型近似於對 20 項指標等權重加總。

模型式（特徵已標準化）：

$$\hat{y} = \beta_0 + \sum_{j=1}^{20} \beta_j z_j, \quad z_j = \frac{x_j - \bar{x}_j}{s_j}$$

statsmodels OLS 結果（訓練集 894,365 筆）

指標	數值	解讀
R^2 / Adjusted R^2	0.845 / 0.845	解釋 84.5% 的變異；樣本極大，兩者幾乎相同
F-statistic	2.437×10^5（p ≈ 0）	整體模型顯著
截距 β_0	0.5045	等於目標平均值，因為特徵已標準化
係數 β_1 ~ β_{20}	+0.0115 ~ +0.0118	全為正值且幾乎相同
t 值	543 ~ 556（p < 0.001）	每個特徵都極顯著
Cond. No.	1.13	與 VIF 一致，無共線性

	Model	CV Mean R^2	CV Std R^2	Best Alpha
0	LinearRegression	0.844959	0.000379	N/A
1	RidgeCV	0.844959	0.000379	2.1544
2	LassoCV	0.844958	0.000379	9.673127e-06

係數意義：特徵每增加 1 個標準差，洪水機率約增加 1.2 個百分點。換算回原始單位（0.0117 ÷ 標準差約 2.07），每增加 1 分約增加 0.56 個百分點。任何一項風險指標的影響力都差不多。

模型比較：另以 sklearn 建立 LinearRegression、RidgeCV、LassoCV，並在訓練集做 5-fold 交叉驗證，三者平均 R^2 皆約 0.845、標準差極小，結果穩定。正則化幾乎沒有作用，因為特徵幾乎正交、樣本極大，OLS 係數已非常穩定。

基準模型：只用相關最高的 DeterioratingInfrastructure 做單純線性回歸，作為「單變數 vs 多變數」的對照。

6. Evaluation

20 個特徵的模型在驗證集 R^2 為 0.8449、Kaggle Private Score 為 0.84426，兩者一致，沒有過擬合；但殘差顯示仍有線性模型抓不到的非線性結構。

6.1 驗證集評估指標（223,592 筆）

模型	特徵數	MAE	MSE	RMSE	R^2	Adjusted R^2
Baseline 單純線性回歸	1	0.040173	0.002504	0.050036	0.036824	0.036820
statsmodels OLS	20	0.015792	0.000403	0.020080	0.844877	0.844863
LinearRegression	20	0.015792	0.000403	0.020080	0.844877	0.844863
RidgeCV	20	0.015792	0.000403	0.020080	0.844877	0.844863
LassoCV	20	0.015796	0.000403	0.020080	0.844877	0.844863

多元模型的 RMSE 比單變數基準模型降低約 60%，R^2 從 0.037 提升到 0.845。

6.2 預測圖與 95% 區間

對新資料 x_0，平均值的信賴區間（mean_ci）與個別觀測值的預測區間（obs_ci）分別為：

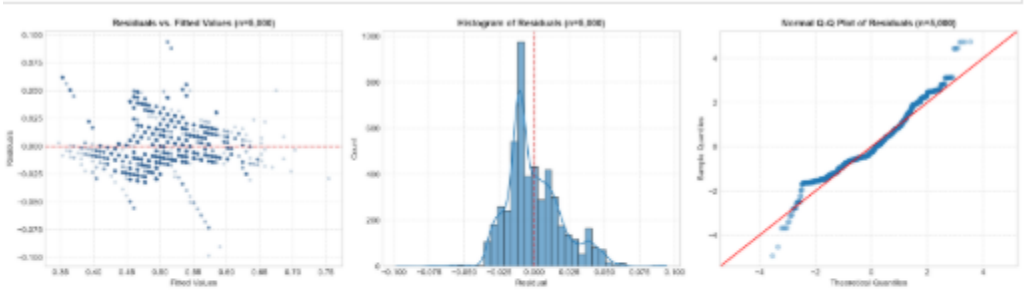
$$\text{CI: } \hat{y}_0 \pm t_{0.975}\, \hat{\sigma}\sqrt{x_0^\top (X^\top X)^{-1} x_0} \qquad \text{PI: } \hat{y}_0 \pm t_{0.975}\, \hat{\sigma}\sqrt{1 + x_0^\top (X^\top X)^{-1} x_0}$$

【插入圖 6-1：Actual vs. Predicted 散佈圖（n = 5,000）】

【插入圖 6-2：95% Confidence and Prediction Intervals for 100 Validation Samples】

- 預測線呈階梯狀，因為特徵都是整數，預測值也是離散的。
- 信賴區間在圖上幾乎看不見：係數標準誤只有約 2×10^{-5}，平均值的不確定性極小。
- 預測區間約為 ±0.04（≈ 1.96 × RMSE），主要來自個別觀測值的隨機雜訊。這正說明兩種區間的差別：樣本越大，信賴區間越窄，預測區間則不會縮小。
- **預測區間覆蓋率**：驗證集 223,592 筆中有 211,543 筆落在 95% 預測區間內，實際覆蓋率 94.61%，接近理論值 95%。略低一點是因為殘差右偏、厚尾，而區間是以常態假設計算。

6.3 殘差診斷



```
=== Residual Diagnostic Statistical Tests ===
1. Durbin-Watson Statistic: 1.9989
2. Breusch-Pagan Heteroscedasticity Test:
   - Lagrange Multiplier (LM) Stat: 9617.5896
   - LM Test p-value:               0.0000e+00
   - F-Statistic:                   502.4466
   - F-Test p-value:                0.0000e+00
```

檢查項目	結果	判定
自相關	Durbin-Watson = 1.999	成立，無自相關
常態性	偏態 0.706、峰度 4.10；Jarque-Bera p ≈ 0；Q-Q 圖呈 S 形	部分成立
變異同質性	Breusch-Pagan LM = 9,617.59，p ≈ 0；中段較分散、兩端較集中	部分成立
共線性	VIF ≤ 1.0037、Cond. No. = 1.13	成立

- 殘差 vs 預測值圖有斜條紋，來自目標以 0.005 為單位的離散值。
- 殘差直方圖峰值約在 -0.01，右側 +0.04 附近有次峰。
- 樣本超過 80 萬時，檢定幾乎必定顯著，因此以圖形為主判讀；本例圖形也確實可見偏離。
- **結論**：模型仍有約 15.5% 的變異未解釋，殘差結構顯示資料中有線性模型無法捕捉的非線性關係。

6.4 Kaggle 提交結果

以全部訓練資料重新訓練後，預測 745,305 筆測試資料並提交（競賽已結束，屬 Late Submission，有分數但不列入名次）。

資料集	R^2

資料集	R^2
驗證集	0.84488
Kaggle Public Score	0.84458
Kaggle Private Score	0.84426

三個分數相差不到 0.001，模型泛化能力良好。

7. Deployment

最終模型已輸出為輕量 JSON 參數檔，只需 numpy 就能回傳預測值與 95% 預測區間。

1. **重新訓練**：以全部 1,117,957 筆訓練資料重新 fit StandardScaler 與 OLS。
2. **儲存模型**：`model/model_params.json` 內含特徵名稱、標準化參數（mean、scale）、回歸係數與截距、$(X^TX)^{-1}$、殘差變異數與自由度。
3. **預測函式**：`predict_flood(features)` 輸入 20 個特徵值，回傳預測值與 95% 預測區間上下界。
4. **一致性驗證**：以 test.csv 第一筆（id = 1117957）測試，預測值 0.573615、95% 預測區間 [0.534234, 0.612996]，與批次預測差距僅 1.11×10^{-16}。
5. **Kaggle 提交檔**：745,305 筆、無缺失值，預測範圍 0.3024 ~ 0.7600、平均 0.5045。

【插入圖 7-1：predict_flood() 示範輸出】

部署方式：由於不需安裝 scikit-learn 或 statsmodels，可直接包裝為 FastAPI 預測端點，部署到 Vercel，延續 HW1 天氣網站的架構。

適用情境：作為洪水風險的初步評估工具，比較不同區域的相對風險，並同時提供預測的不確定性。

限制

- 資料為 Kaggle 合成資料，不代表真實地區的洪水風險。
- 殘差非常態，預測區間實際覆蓋率為 94.61%，略低於 95%。
- 線性模型沒有上下限：測試集預測最大值 0.760 高於訓練資料最大值 0.725，屬於外推。
- 約 15.5% 的變異未解釋，存在線性模型無法捕捉的非線性關係。

8. 主流解法比較

本作業的線性回歸（Private 0.8443）與冠軍解法（約 0.8694）相差約 0.025，已取得約 97% 的可達預測力，且在可解釋性與部署上明顯較優。

項目	本作業：多元線性回歸	線性模型 + 特徵工程	梯度提升樹（LightGBM 等）	冠軍解法（集成）
R^2	0.8443（Kaggle Private）	約 0.852 ~ 0.867	約 0.868 ~ 0.869	約 0.8694

項目	本作業：多元線性回歸	線性模型 + 特徵工程	梯度提升樹（LightGBM 等）	冠軍解法（集成）
特徵	原始 20 個	總和的 One-Hot 編碼、特殊總和區間標記	列統計量（sum、std、max、分位數）、排序、計數特徵	同左，再加目標編碼
可解釋性	極高，每個係數有明確意義	中等	低	極低
訓練成本	數秒	低	中等	極高（30 個以上模型）
預測區間	有理論基礎，可直接計算	可計算	需額外方法	需額外方法
部署	只需 numpy 與一個 JSON 檔	簡單	需模型套件	複雜

差距來源：主流解法指出洪水機率在特徵總和特定區間（約 72–75）會異常升高，且風險在各指標間的分佈型態（標準差、極值）也有資訊。這些非線性結構解釋了本作業殘差中的次峰與斜條紋。

特徵總和為何對線性模型無效、對樹模型有效：總和是原始特徵的線性組合，線性回歸本來就學得到；但樹模型只能沿單一欄位切分，難以自行學出跨 20 欄的加總，因此需要手動提供。

改進方向：若要在維持線性模型的前提下提升分數，可加入特徵總和的 One-Hot 編碼；若追求最高準確度，可改用梯度提升樹搭配列統計特徵。

9. 【NotebookLM 摘要】

本節由 NotebookLM 彙整以下來源後整理：Kaggle S4E5 冠軍解法（1st place solution）、Flood Prediction Regression – LightGBM、PSS4E5 EDA which makes sense、Regression Flood Analysis。

本資料集為合成資料，20 個特徵的分佈、與目標的相關性幾乎一致且彼此獨立，因此決定洪水機率的關鍵不是「哪一個指標高」，而是 20 個指標的「總體累積風險」。多份分析指出，僅將 20 個特徵加總乘以約 0.0056 再減去約 0.05，就能得到 R^2 約 0.845。這與本作業 OLS 的結果一致：每個特徵每增加 1 分，洪水機率約增加 0.56 個百分點，Kaggle Private R^2 為 0.8443。

主流的高分解法進一步加入列統計特徵（總和、標準差、最大值、分位數、特定數值出現次數）與特徵排序，搭配 LightGBM、XGBoost、CatBoost 等梯度提升樹，單一模型 R^2 可達約 0.869；冠軍解法則融合 30 個以上模型的 OOF 預測，再以 Ridge 回歸堆疊，R^2 約 0.8694。

此外，有分析發現特徵總和落在 72–75 時，洪水機率會異常升高。線性回歸若未手動加入此類標記，無法自動捕捉，這也解釋了本作業殘差中觀察到的結構。綜合而言，線性回歸是極強的基準模型，而準確度的天花板來自未建模的非線性結構。

10. 【GPT 輔助內容】

本作業使用三種 AI 工具輔助，所有數據結果皆經實際執行驗證，AI 產生的說明已依實際輸出逐一校正。

工具	用途	對應章節
ChatGPT	討論特徵選擇方法、信賴區間與預測區間的差別、線性回歸假設（完整對話見附錄 PDF）	第 4–6 章的方法設計
Antigravity（Gemini）	協助撰寫 notebook 程式碼與各章節說明文字	第 2–7 章的程式碼
Claude	規劃 CRISP-DM 流程、檢查輸出數字、修正說明、整理本報告	全篇

驗證與校正紀錄：AI 產生的說明曾出現與實際輸出不符的數字，均已對照 notebook 輸出修正：

- 資料筆數：1,117,958 修正為實際的 1,117,957。
- VIF 範圍：1.0000 ~ 1.0010 修正為 1.0017 ~ 1.0037。
- OLS 係數：+0.0464 ~ +0.0471 修正為 +0.0115 ~ +0.0118；「提升 4.6%」修正為「約 1.2 個百分點」；t 值「超過 800」修正為 543 ~ 556。
- 預測區間覆蓋率：95.1% 修正為 94.61%。
- 殘差診斷：原描述「均勻帶狀、Q-Q 圖貼合」，依實際圖形改寫為「有斜條紋、殘差右偏且非常態」。

使用 AI 的心得：AI 能大幅加快程式撰寫，但其摘要可能在程式尚未執行前就先寫好結論，必須以實際輸出為準。

11. 結論

多元線性回歸以 20 個特徵達到 Kaggle Private R^2 0.8443，比單一特徵模型的 0.037 高出 20 倍以上，證實本問題需要多變數建模。

1. 特徵選擇顯示 20 個特徵均有貢獻，三種方法結論一致。
2. 模型近似等權重加總，每個指標每增加 1 分，洪水機率約增加 0.56 個百分點，與網路上的分析結果一致。
3. 驗證集、Kaggle Public 與 Private 分數相差不到 0.001，泛化能力良好；95% 預測區間覆蓋率 94.61%。

4. 殘差非常態且有結構，顯示約 15.5% 的變異來自非線性關係；主流解法以列統計特徵加梯度提升樹可提升至約 0.869。
5. 線性模型具備可解釋、有理論基礎的預測區間與輕量部署等優勢，適合需要說明決策依據的防災情境。

附錄

- 附錄 A：ChatGPT 對話紀錄（另附 PDF：7115064011_GPT 對話.pdf）
- 附錄 B：主程式 7115064011_hw2.ipynb
- 附錄 C：GitHub 專案與 README：AIoT-HW2-regression

Sources

- Kaggle Playground Series S4E5 – Regression with a Flood Prediction Dataset
- NotebookLM 彙整來源：1st place solution、Flood Prediction Regression – LightGBM、PSS4E5 EDA which makes sense、Regression Flood Analysis（均來自上述競賽的 Code 與 Discussion 頁面）